



elasticsearch

elasticsearch

Elasticsearch

Pau Recacha Borrell
Miguel Ángel Bueno Rivera
Ferran Rodríguez Martínez

Minimum Viable Product (MVP)

- Aplicació Android de consulta, compra i venda d'articles d'usuaris.
- Obtenir beneficis a través d'un percentatge de les transaccions o anuncis que es poden afegir a l'aplicació.

Les 6 W

- What?
Producte relativament econòmic amb grans capacitats per a obtenir beneficis en el futur.
- Why?
Globalització. Capitalisme. Senzillesa.
- Where?
Per regions; continents, països.
- When?
ARA.
- How?
Aplicació i registre gratuït.
- Who?
Qualsevol usuari.

Què comporta?

- Aplicació ràpida i fàcil de fer servir.
- Disponibilitat i consistència de les dades.
- Una o vàries bases de dades grans.
- Consultes àgils.
- Transaccions eficients.
- Monitorització.

Entorn de treball

Dades

- Elasticsearch
- Kibana
- Logstash
- MySQL
- Ngrok

Aplicació

- IntelliJ IDEA
- Android
- Retrofit 2



logstash



elasticsearch



kibana

Data
Aggregation
& Processing

Indexing &
storage

Analysis &
visualization



elasticsearch

ElasticSearch

Que és?

Motor de cerca i anàlisis (Java - codi obert)

Cerques molt ràpides

Servei API REST (Index, Get, Delete, Update)



Ara és el més potent


ElasticSearch per dins

Com funciona l'estructura?



NOTE

Each Elasticsearch shard is a Lucene index. There is a maximum number of documents you can have in a single Lucene index. As of [LUCENE-5843](#), the limit is 2,147,483,519 (= Integer.MAX_VALUE - 128) documents. You can monitor shard sizes using the [_cat/shards](#) API.



ElasticSearch

Característiques

- **Cerques ràpides** en Big Data
- **Visualització de dades** immediata
- **Desnormalització:** proximitat entre els documents guardats = rapidesa
- **Distribuïda i altament escalable**

AVANTATGES

ElasticSearch



- **Construït sobre lucene**
- **Autocompletat i recerca instantània**
- **Fuzzy searching:** recerca difusa
- **Descobriments de nous productes i serveis**

Organitzacions que l'utilitzen

Mercado Libre

4 milions de venedors actius

20 milions de productes en temps real

No cal reindexar totes les dades cada vegada que s'afegeix un atribut nou



Organitzacions que l'utilitzen

Telefónica

Solució per al **creixement** dels serveis de **vídeo sota demanda**

Identifica problemes que podrien quedar ocults d'un altre mode



Telefónica

Altres: Facebook, Activision, IBM, ebay, justEat, tinder ...

ELK

Què és Kibana?

- Eina open-source.
- Permet visualitzar dades indexades a Elasticsearch.
- Múltiples packs de software i eines que faciliten tasques als usuaris.
- Monitorització de dades: fluctuacions, rendiment, dashboards, etc.

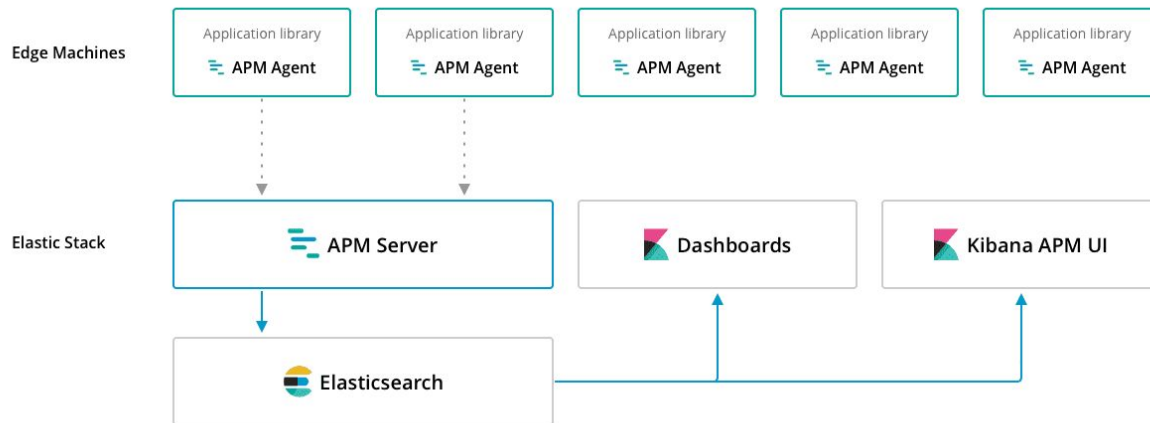


kibana

Kibana APM





APM




Security Analytics



Use an expression language to analyze time series data and visualize the results.



Metrics





```
1 # {dpcindex}/{doctype}/{id}
2
3 # Get les categories amb les subcategories
4 GET categories/categoria/_search
5
6 # Get les subcategories de la categoria Electronics
7 GET categories/categoria/Electronics
8
9 # Get igual que el anterior, pero fent ús de els
  filtres del querydsl
10 GET categories/categoria/_search
11 {
12   "query": {
13     "match": {
14       "_id": "Electronics"
15     }
16   }
17 }
18
19 # Get els productes guardats
20 GET productes/producte/_search
21
22 # Get del producte amb id (substituir id pel que
  calgui)
23 GET productes/producte/12245
24
25
26
27
28
29
```

```
1 {
2   "took": 9,
3   "timed_out": false,
4   "_shards": {
5     "total": 5,
6     "successful": 5,
7     "skipped": 0,
8     "failed": 0
9   },
10   "hits": {
11     "total": 5,
12     "max_score": 1,
13     "hits": [
14       {
15         "_index": "categories",
16         "_type": "categoria",
17         "_id": "Apple CarPlay",
18         "_score": 1,
19         "_source": {
20           "subcategories": "Auto & Tires",
21           "type": "categoria",
22           "nom": "Apple CarPlay",
23           "@version": "1",
24           "@timestamp": "2018-12-18T23:44:00.100Z"
25         }
26       },
27       {
28         "_index": "categories",
29         "_type": "categoria",
30         "_id": "Electronics",
31         "_score": 1,
32         "_source": {
33           "subcategories": "Audio & Video Accessories,Stereos,Computers,Portable Bluetooth Speakers,Surround Speakers
,Internal Solid State Drives,Bluetooth & Wireless Speakers,Electronics,Headphones,Audio Power Conditioners
,Parts & Accessories,Accessories,In-Wall & In-Ceiling Speakers,Office,Marine Audio,Computer Accessories &
Peripherals,Computers & Accessories,Straps & Hand Grips,Backpacks ffvzrebezbzuqvcddwzzxeuwva,LCD TVs,Frys
,Computers/Tablets & Networking,Consumer Electronics,Subwoofers,Car Electronics & GPS,LED & LCD TVs,Auto &
Tires,Video Games & Consoles,Satellite Radio,Desktop Memory,Samsung Tax Time Savings,Sports & Outdoors,Audio
,Floor Speakers,TV & Video,Home & Garden,Mobile,Outdoor Speakers,Towers,See more Samsung Ubd-m9500 4k Ultra
HD Blu-ray Player,TV,Photography,Digital Cameras,TVs & Electronics,Camera & Photo Accessories,Controllers,All
TVs,Used:Film Camera Lens Accessories,Home Theater Systems,Speaker Separates,Cameras & Photo,Samsung Smart
TVs,4K Ultra HD TVs,Tablets,Receivers Amplifiers,Touch-Screen All-in-One Computers,Home Audio,Android Auto
Receivers,Audio Visual Presentation,Wireless Multi-Room Speakers uytueusqxdvcfrxftfeefvcxudq,Sports &
Handheld GPS The Wall Chosen Event Micro SD (SD Bluetooth Headsets Prime Lenses TVs & Entertainment Solar &
```



ELK

Que és LogStash?

- Eina intermitja entre Kibana i ElasticSearch.
- Disposa d'una gran quantitat de plugins
- Multi servidor. Vàries pipelines.



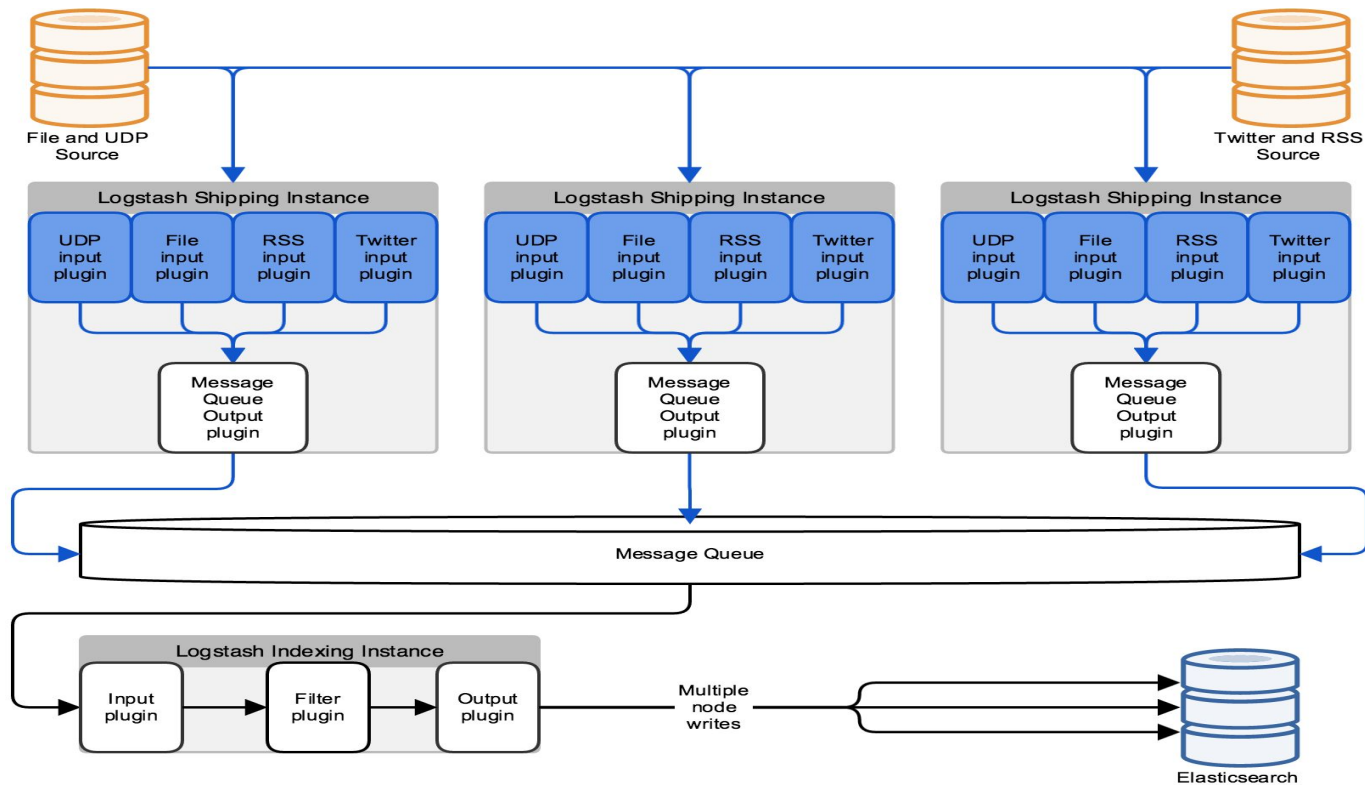
logstash



logstash

LogStash

Com funciona?



Beats

L'últim afegit a ELK

- ElasticStack, fa relativament poc, va ampliar-se amb un producte nou:
 - ElasticSearch
 - Kibana
 - LogStash
 - (+) Beats
- Beats és una família d'agents encarregats de recollir dades.



beats

Beats

La familia beats



The Beats family



Packetbeat

Network data



Metricbeat

Metrics



Winlogbeat

Windows Event Logs



Auditbeat

Audit data



Filebeat

Log files



Heartbeat

Uptime monitoring

+40
community
Beats



Preparació entorn

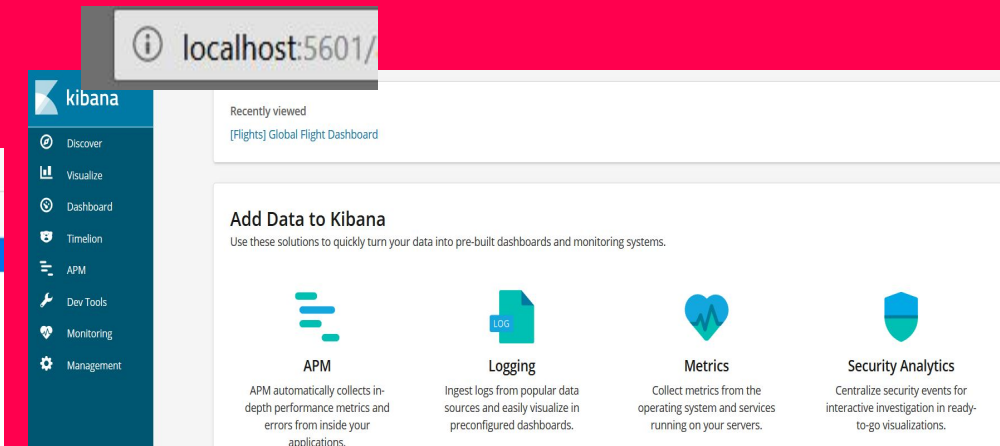
Muntatge del sistema ELK

ElasticSearch i Kibana

```
localhost:9200

Guardar Copiar Contraer todo Expandir todo

name: "45Zhssz"
cluster_name: "elasticsearch"
cluster_uuid: "kDfZxwjSRT-RAv28bHTNVg"
version:
  number: "6.5.2"
  build_flavor: "default"
  build_type: "zip"
  build_hash: "9434bed"
  build_date: "2018-11-29T23:58:20.891072Z"
  build_snapshot: false
  lucene_version: "7.5.0"
  minimum_wire_compatibility_version: "5.6.0"
  minimum_index_compatibility_version: "5.0.0"
tagline: "You Know, for Search"
```



Elasticsearch

(elasticsearch.yml)

```
##### Elasticsearch Configuration #####
#
# NOTE: Elasticsearch comes with reasonable defaults for most settings.
#       Before you set out to tweak and tune the configuration, make sure you
#       understand what are you trying to accomplish and the consequences.
#
# The primary way of configuring a node is via this file. This template lists
# the most important settings you may want to configure for a production cluster
#
# Please consult the documentation for further information on configuration of
# https://www.elastic.co/guide/en/elasticsearch/reference/index.html
#
# ----- Cluster -----
#
# Use a descriptive name for your cluster:
#
#cluster.name: my-application
#
# ----- Node -----
#
# Use a descriptive name for the node:
#
#node.name: node-1
#
# Add custom attributes to the node:
#
#node.attr.rack: r1
#
# ----- Paths -----
#
# Path to directory where to store the data (separate multiple locations by comma)
#
#path.data: /path/to/data
#
# Path to log files:
#
#path.logs: /path/to/logs
#
```

```
# ----- Memory -----
#
# Lock the memory on startup:
#
#bootstrap.memory_lock: true
#
# Make sure that the heap size is set to about half the memory available
# on the system and that the owner of the process is allowed to use this
# limit.
#
# Elasticsearch performs poorly when the system is swapping the memory.
#
# ----- Network -----
#
# Set the bind address to a specific IP (IPv4 or IPv6):
#
#network.host: 0.0.0.0
#
# Set a custom port for HTTP:
#
#http.port: 9200
#
# For more information, consult the network module documentation.
#
# ----- Discovery -----
#
# Pass an initial list of hosts to perform discovery when new node is started:
# The default list of hosts is ["127.0.0.1", "[::1]"]
#
#discovery.gsn.ping.unicast.hosts: ["host1", "host2"]
#
# Prevent the "split brain" by configuring the majority of nodes (total number of master-eligible nodes / 2 + 1):
#
#discovery.gsn.minimum_master_nodes:
#
# For more information, consult the gsn discovery module documentation.
#
# ----- Gateway -----
#
# Block initial recovery after a full cluster restart until N nodes are started:
#
#gateway.recover_after_nodes: 3
#
# For more information, consult the gateway module documentation.
#
# ----- Various -----
#
# Require explicit names when deleting indices:
#
#action.destructive_requires_name: true
```

Muntatge ELK

Dades emmagatzemades a MySQL DB

- Base de dades extretes de: <https://data.world/> amb petites modificacions
- Apache POI per xlsx i Java
- Taules producte, categoria i condicions.

Table: **producte**

Columns:

<u>codi</u>	int(11) AI PK
dataInsercio	datetime
disponibilitat	int(11)
condicions	varchar(20)
nom	varchar(200)
marca	varchar(40)
fabricant	varchar(100)
preu	float(8,2)
preuEnviament	float(8,2)
categoriaPrincipal	varchar(30)
altreCategoria	varchar(200)
imageURL	varchar(400)

Table: **categoria**

Columns:

<u>nom</u>	varchar(50) PK
subcategories	varchar(4000)

Table: **condicions**

Columns:

<u>nom</u>	varchar(50) PK
-------------------	----------------

Logstash: INPUT i OUTPUT

```
input {
  jdbc {
    jdbc_connection_string => "jdbc:mysql://localhost:3306/productes"
    jdbc_user => "root"
    jdbc_password => "root"
    schedule => "*" * * * *
    jdbc_validate_connection => true
    jdbc_driver_library => "C:\\Program Files (x86)\\MySQL\\Connector J 8.0\\mysql-connector-java-8.0.13.jar"
    jdbc_driver_class => "com.mysql.cj.jdbc.Driver"
    statement => "SELECT * from productes"
    type => "productes"
  }
  jdbc {
    jdbc_connection_string => "jdbc:mysql://localhost:3306/productes"
    jdbc_user => "root"
    jdbc_password => "root"
    schedule => "*" * * * *
    jdbc_validate_connection => true
    jdbc_driver_library => "C:\\Program Files (x86)\\MySQL\\Connector J 8.0\\mysql-connector-java-8.0.13.jar"
    jdbc_driver_class => "com.mysql.cj.jdbc.Driver"
    statement => "SELECT * from categoria"
    type => "categoria"
  }
  jdbc {
    jdbc_connection_string => "jdbc:mysql://localhost:3306/productes"
    jdbc_user => "root"
    jdbc_password => "root"
    schedule => "*" * * * *
    jdbc_validate_connection => true
    jdbc_driver_library => "C:\\Program Files (x86)\\MySQL\\Connector J 8.0\\mysql-connector-java-8.0.13.jar"
    jdbc_driver_class => "com.mysql.cj.jdbc.Driver"
    statement => "SELECT * from condicions"
    type => "condicions"
  }
}
```

```
output {
  if [type] == "productes" {
    elasticsearch {
      hosts => "localhost:9200"
      index => "productes"
      document_type => "%{type}"
      document_id => "%{codi}"
    }
  }
  if [type] == "categoria" {
    elasticsearch {
      hosts => "localhost:9200"
      index => "categories"
      document_type => "%{type}"
      document_id => "%{nom}"
    }
  }
  if [type] == "condicio" {
    elasticsearch {
      hosts => "localhost:9200"
      index => "condicions"
      document_type => "%{type}"
      document_id => "%{nom}"
    }
  }
}
```

Execució: logstash.bat -f logstash.conf

Rufus Scheduler:

minut hora dia mesos(int) UTC

MySQL DB:

SET @@global.time_zone='+00:00';

SET @@session.time_zone='+00:00';

Filtres logstash(extres)

```
filter {  
  mutate { remove_field => [ "field1", "field2", "field3", ... "fieldN" ] }  
}
```

La gran majoria de camps es poden filtrar excepte els que són de sistema, com els `_index`, `_type`, `_id`, `_source`. Altres que directament es generen a l'hora de fer la cerca com és el `_score`. O altres com per exemple el `@timestamp`, que són necessaris.

Ngrok

ngrok.exe http port

ngrok by @inconshreveable

```
Session Status      online
Account             Miguel Ángel Bueno Rivera (Plan: Free)
Version             2.2.8
Region              United States (us)
Web Interface       http://127.0.0.1:4040
Forwarding           http://c3c61862.ngrok.io -> localhost:9200
Forwarding           https://c3c61862.ngrok.io -> localhost:9200
```

Connections	ttl	opn	rt1	rt5	p50	p90
	0	3	0.00	0.00	0.00	0.00

HTTP Requests


```
GET /favicon.ico          200 OK
GET /productes/producte/_search 200 OK
GET /productes/producte/_search 200 OK
GET /condicions/condicio/_search 200 OK
GET /productes/producte/_search 200 OK
GET /categories/categoria/_search 200 OK
GET /productes/producte/_search 200 OK
```

Muntatge ELK

Crides REST

Algunes funcionalitats de la aplicació, requereixen agafar dades dels documents indexats a l'elasticsearch fent ús de crides REST, com per exemple:

- productes (per o id o tots)
`@GET("/productes/producte/{id}")`
`@GET("/productes/producte/_search")`
- categories (subcategories, categories)
`@GET("/categories/categoria/_search")`
`@GET("/categories/categoria/{id}")`




Futurs canvis en la aplicació - ELK

- Utilitzar l'eina APM per rebre informació d'execució de l'aplicació i possibles errors que es produeixin en elles
- Implementar un servei de login i utilitzar el FileBeat per captar informació que ens interressi sobre aquests. I/o utilitzar Logging per utilitzar ja les dashboards pre-dissenyades.
- Millorar la distribució dels shards, repliques i ampliar informació.
- Ampliar la bases de dades, establir un schedule, exportar les dades d'elasticsearch a MySQL.
- Logs, millorar app, transaccions, seguretat, custom url keys, etc.

Exemple query

```
GET _search
{
  "query": {
    "bool": {
      "must": {
        "match": {
          "nom": "tv"
        }
      },
      "filter": {
        "range": { "disponibilitat": { "gte": 30 }}
      }
    }
  }
}
```



Gràcies!!

Pau Recacha Borrell
Ferran Rodríguez
Miguel Ángel Bueno Rivera

Webgrafia

<https://github.com/jmettraux/rufus-scheduler>

<https://www.elastic.co/guide/en/logstash/5.0/plugins-inputs-jdbc.html>

https://www.elastic.co/*

https://stackoverflow.com/*

https://lucene.apache.org/core/2_9_4/queryparsersyntax.html

<https://developer.android.com/>

<https://square.github.io/retrofit/>

<https://www.elastic.co/guide/en/elasticsearch/reference/current/docs-get.html>