

Elasticsearch

Pau, Miguel i Ferran

Sistema de gestió de BD, GEINF

Minimum Viable Product (MVP)

- Aplicació Android de consulta, compra i venta d'articles d'usuaris.
- Obtenir beneficis a través d'un percentatge de les transaccions o anuncis que es poden afegir a l'aplicació.

Les 6 W

What?
 Producte relativament econòmic amb grans capacitats per a obtenir beneficis en el futur.

- Why?
 Globalització. Capitalisme. Senzillesa.
- Where?
 Per regions; continents, països.
- When? ARA.
- How?
 Aplicació i registre gratuït.
- Who?
 Qualsevol usuari.

Què comporta?

- Aplicació ràpida i fàcil de fer servir.
- Disponibilitat i consistència de les dades.
- Una o vàries bases de dades grans.
- Consultes àgils.
- Transaccions eficients.
- Monitorització.

Entorn de treball

Dades

- Elasticsearch
- Kibana
- Logstash
- MySQL
- Ngrok

Aplicació

- IntelliJ IDEA
- Android
- Retrofit 2



Data Aggregation & Processing Indexing & storage

Analysis & visualization



ElasticSearch Que és?

Motor de cerca i anàlisis (Java - codi obert)

Cerques molt ràpides

Servei API REST (Index, Get, Delete, Update)



Ara és el més potent

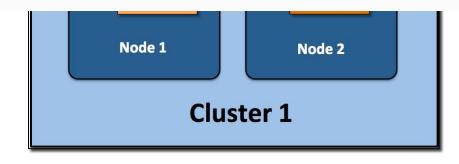
ElasticSearch per dins

Com funciona l'estructura?





Each Elasticsearch shard is a Lucene index. There is a maximum number of documents you can have in a single Lucene index. As of Lucene-5843, the limit is 2,147,483,519 (= Integer.MAX_VALUE - 128) documents. You can monitor shard sizes using the __cat/shards API.









- Cerques ràpides en Big Data
- Visualització de dades immediata

- Desnormalització:

 proximitat entre els
 documents guardats
 = rapidesa
- Distribuïda i altament escalable

AVANTATGES ElasticSearch



- Construit sobre lucene

 Autocompletat i recerca instantània

 Fuzzy searching: recerca difusa Descobriment de nous productes i serveis

Organitzacions que l'utilitzen

Mercado Libre



4 milions de venedors actius

20 milions de productes en temps real

No cal reindexar totes les dades cada vegada que s'afegeix un atribut nou



Organitzacions que l'utilitzen Telefònica



Solució per al **creixement** dels serveis de **vídeo sota demanda**

Identifica problemes que podrien quedar ocults d'un altre mode



Altres: Facebook, Activision, IBM, ebay, justEat, tinder ...

ELK Què és Kibana?

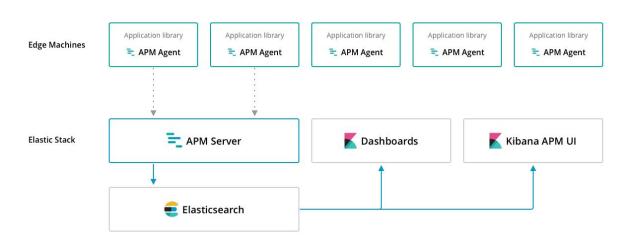
- Eina open-source.
- Permet visualitzar dades indexades a ElasticSearch.
- Múltiples packs de software i eines que faciliten tasques als usuaris.
- Monitorització de dades: fluctuacions, rendiment, dashboards, etc.





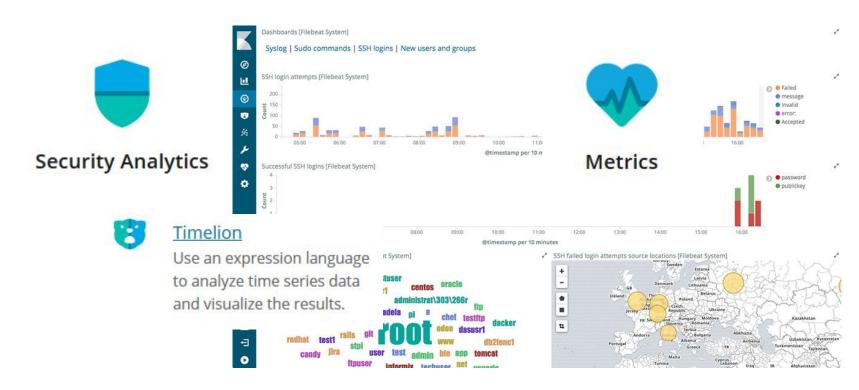
Kibana APM

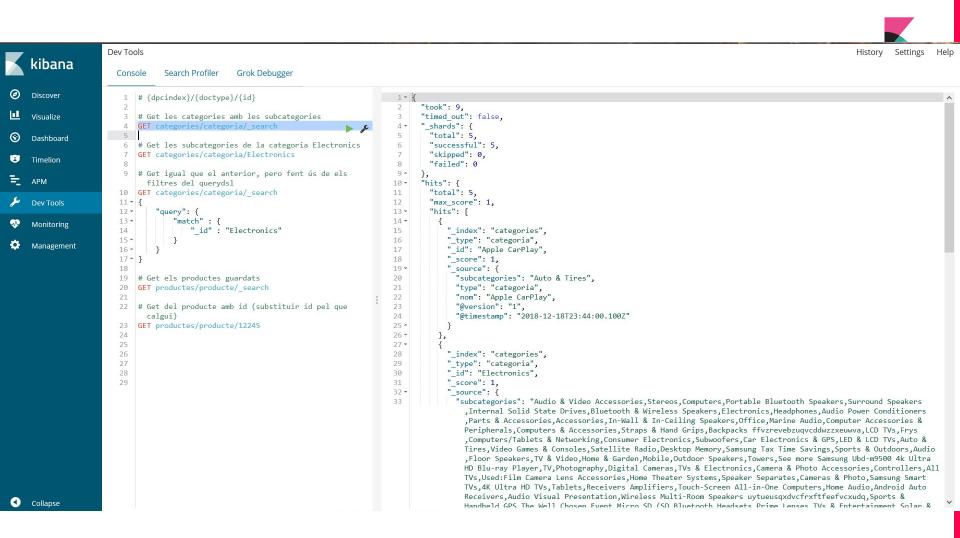






Kibana Security Analytics





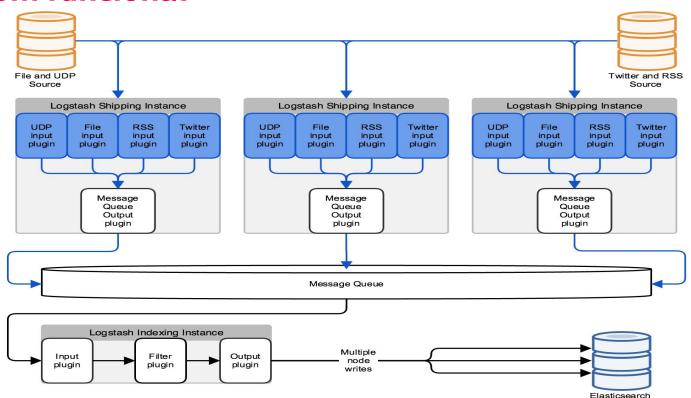
ELK Que és LogStash?

- Eina intermitja entre Kibana i ElasticSearch.
- Disposa d'una gran quantitat de plugins
- Multi servidor. Vàries pipelines.



logstash

LogStash
Com funciona?





Beats

L'últim afegit a ELK

- ElasticStack, fa relativament poc, va ampliar-se amb un producte nou:
 - ElasticSearch
 - Kibana
 - LogStash
 - (+) Beats
- Beats és una família d'agents encarregats de recollir dades.



beats

Beats La familia beats







Packetbeat

Network data



Auditbeat

Audit data



Metricbeat

Metrics



Filebeat

Log files



Winlogbeat

Windows Event Logs



Heartbeat

Uptime monitoring

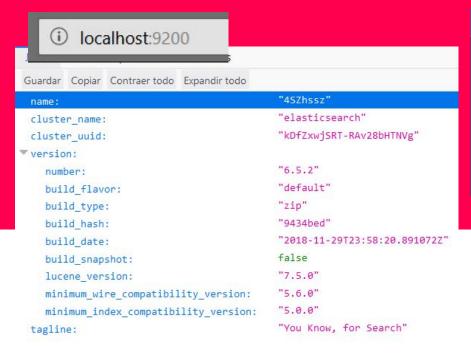


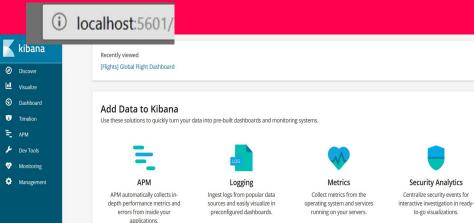




Preparació entorn

Muntatge del sistema ELK ElasticSearch i Kibana





Elasticsearch (elasticsearch.yml)

```
Elasticsearch Configuration =====
# NOTE: Elasticsearch comes with reasonable defaults for most settings.
       Before you set out to tweak and tune the configuration, make sure you
       understand what are you trying to accomplish and the consequences.
# The primary way of configuring a node is via this file. This template lists
  the most important settings you may want to configure for a production clust
# Please consult the documentation for further information on configuration
  https://www.elastic.co/guide/en/elasticsearch/reference/index.html
# Use a descriptive name for your cluster:
#cluster.name: mv-application
# Use a descriptive name for the node:
#node.name: node-1
# Add custom attributes to the node:
#node.attr.rack: rl
# Path to directory where to store the data (separate multiple locations by co.
#path.data: /path/to/data
# Path to log files:
#path.logs: /path/to/logs
```

```
# Lock the memory on startup:
#bootstrap.memory lock: true
# Make sure that the heap size is set to about half the memory available
# on the system and that the owner of the process is allowed to use this
# Elasticsearch performs poorly when the system is swapping the memory.
# Set the bind address to a specific IP (IPv4 or IPv6):
fnetwork bost: 0 0 0 0
# Set a custom port for HTTP:
#http.port: 9200
# For more information, consult the network module documentation.
 Pass an initial list of hosts to perform discovery when new node is started:
# The default list of hosts is ["127.0.0.1", "[::1]"]
#discovery.zem.ping.unicast.hosts: ["host1", "host2"]
 Prevent the "split brain" by configuring the majority of nodes (total number of master-eligible nodes / 2 + 1):
#discovery.zem.minimum master nodes:
 For more information, consult the zen discovery module documentation.
           ----- Gateway -----
# Block initial recovery after a full cluster restart until N nodes are started:
 For more information, consult the gateway module documentation.
 Require explicit names when deleting indices:
#action.destructive requires name: true
```

Muntatge ELK

Dades emmagatzemades a MySQL DB

- Base de dades extretes de: <u>https://data.world/</u> amb petites modificacions
- Apache POI per xlsx i Java
- Taules producte, categoria i condicions.

Table: producte

int(11) AI PK datetime int(11) varchar(20) varchar(200) varchar(40) varchar(100) float(8,2) float(8,2) varchar(30) varchar(200) varchar(400)

Table: categoria

Columns:

nom varchar(50) Pi subcategories varchar(4000)

Table: condicions

Columns:

nom varchar(50) PK

Logstash: INPUT i OUPTPUT

```
input
        jdbc connection string => "jdbc:mysgl://localhost:3306/productes"
        jdbc user => "root"
        idbc password => "root"
        schedule => "* * * * * "
        jdbc_validate_connection => true
        jdbc driver library => "C:\Program Files (x86)\MySQL\Connector J 8.0\mysgl-connector-jaya-8.0.13.jar"
        jdbc driver class => "com.mysgl.cj.jdbc.Driver"
        statement => "SELECT * from producte"
        type => "producte"
        jdbc connection string => "jdbc:mysgl://localhost:3306/productes"
        jdbc user => "root"
        jdbc password => "root"
        schedule => "* * * * *"
        jdbc validate connection => true
        jdbc driver library => "C:\Program Files (x86)\MySQL\Connector J 8.0\mysql-connector-jaya-8.0.13.jar"
        jdbc_driver_class => "com.mysql.cj.jdbc.Driver"
        statement => "SELECT * from categoria"
        type => "categoria"
        jdbc connection string => "jdbc:mysql://localhost:3306/productes"
        jdbc user => "root"
        jdbc password => "root"
        schedule => "* * * * * *
        jdbc validate connection => true
        jdbc driver library => "C:\Program Files (x86)\MySQL\Connector J 8.0\mysql-connector-jaya-8.0.13.jar"
        jdbc driver class => "com.mysgl.cj.jdbc.Driver"
        statement => "SELECT * from condicions"
        type => "condicio"
```

```
output {
    if [type] == "producte"
        elasticsearch
            hosts => "localhost:9200"
            index => "productes"
            document type => "%{type}"
            document id => "%{codi}"
    if [type] == "categoria" {
        elasticsearch {
            hosts => "localhost:9200"
            index => "categories"
            document type => "%{type}"
            document id => "% {nom}"
    if [type] == "condicio"
        elasticsearch {
            hosts => "localhost:9200"
            index => "condicions"
            document type => "%{type}"
            document id => "%{nom}"
```

Execució:logstash.bat -f logstash.conf
Rufus Scheduler:
minut hora dia mesos(int) UTC
MySQL DB:
SET @@global.time_zone='+00:00';
SET @@session.time_zone='+00:00';

Filtres logstash(extres)

```
filter {
  mutate { remove_field => [ "field1", "field2", "field3", ... "fieldN" ] }
}
```

La gran majoría de camps es poden filtrar excepte els que són de sistema, com els _index, _type, _id, _source. Altres que directament es generen a l'hora de fer la cerca com és el _score. O altres com per exemple el @timestamp, que són necessaris.

Ngrok

```
ngrok by @inconshreveable
Account
                              Miguel Á ngel Bueno Rivera (Plan: Free)
Version
                              2.2.8
Region
                              United States (us)
Web Interface
                              http://127.0.0.1:4040
                              http://c3c61862.ngrok.io -> localhost:9200
Forwarding
                              https://c3c61862.ngrok.io -> localhost:9200
Forwarding
Connections
                              ttl
                                              rt1
                                                      rt5
                                                              p50
                                                                      p90
                                      opn
                                              0.00
                                                      0.00
                                                              0.00
                                                                      0.00
HTTP Requests
GET /favicon.ico
                                  200 OK
GET /productes/producte/ search
                                  200 OK
GET /productes/producte/ search
                                  200 OK
GET /condicions/condicio/ search 200 OK
GET /productes/producte/ search
                                  200 OK
GET /categories/categoria/ search 200 OK
GET /productes/producte/ search
                                  200 OK
```

ngrok.exe http port

Muntatge ELK

Crides REST

Algunes funcionalitats de la aplicació, requereixen agafar dades dels documents indexats a l'elasticsearch fent ús de crides REST, com per exemple:

productes (per o id o tots)

@GET("/productes/producte/{id}")

@GET("/productes/producte/ search")

categories (subcategories, categories)
 @GET ("/categories/categoria/ search")

@GET("/categories/categoria/_search")
@GET("/categories/categoria/{id}")



Futurs canvis en la aplicació - ELK

- Utilitzar l'eina APM per rebre informació d'execució de l'aplicació i possibles errors que es produeixin en elles
- Implementar un servei de login i utilitzar el FileBeat per captar informació que ens interessi sobre aquests. I/o utilitzar Logging per utilitzar ja les dashboards pre-dissenyades.
- Millorar la distribució dels shards, repliques i ampliar informació.
- Ampliar la bases de dades, establir un schedule, exportar les dades d'elasticsearch a MySQL.
- Logs, millorar app, transaccions, seguretat, custom url keys, etc.

Exemple query

```
GET _search
  "query": {
    "bool": {
      "must": {
        "match": {
          "nom": "tv"
      "filter": {
        "range": { "disponibilitat": { "gte": 30 }}
```



Gracies!!

Pau Recacha Borrell Ferran Rodríguez Miguel Ángel Bueno Rivera

Webgrafia

https://github.com/jmettraux/rufus-scheduler

https://www.elastic.co/guide/en/logstash/5.0/plugins-inputs-jdbc.html

https://www.elastic.co/*

https://stackoverflow.com/*

https://lucene.apache.org/core/2 9 4/queryparsersyntax.html

https://developer.android.com/

https://square.github.io/retrofit/

https://www.elastic.co/guide/en/elasticsearch/reference/current/docs-get.html